Microsoft

LIVE

Python + IA

Microsoft

LIVE

Python + IA

- 🧠 3/11: LLMs
- ↖ 3/13: Vector embeddings
- 🔍 3/18: RAG
- 🖼️ 3/19: Modelos de Vision
- 🛠️ 3/25: Salidas estructuradas
- 🛡️ 3/27: Calidad y Seguridad

Regístrate @ aka.ms/PythonIA/series

Microsoft

Python + IA

🧠 Modelos de Lenguaje Grande

Gwyneth Peña-Siguenza
Python Cloud Advocate
madebygps.com/about
@madebygps

Hoy cubriremos...

- Cómo funcionan los LLM
- Opciones de modelo
- Uso de los LLM desde Python
- Mejora de los resultados del LLM
- Librerías LLM
- Creación de aplicaciones basadas en LLM

Cómo funcionan los LLM

De seguro que has usado un LLM...

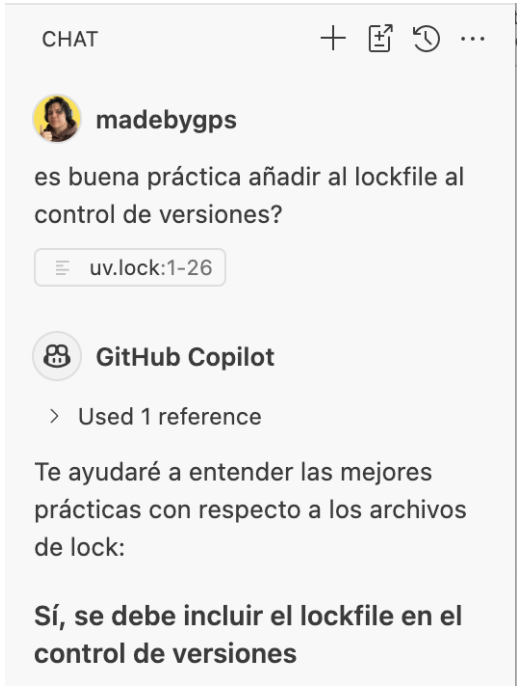

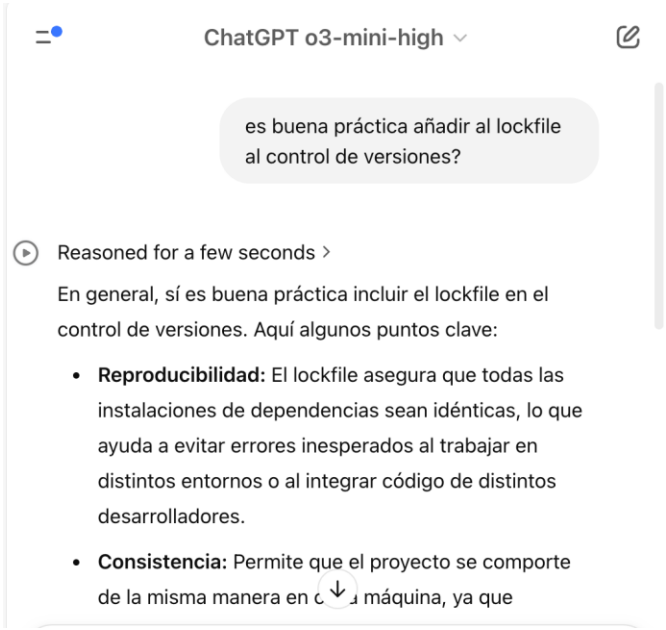

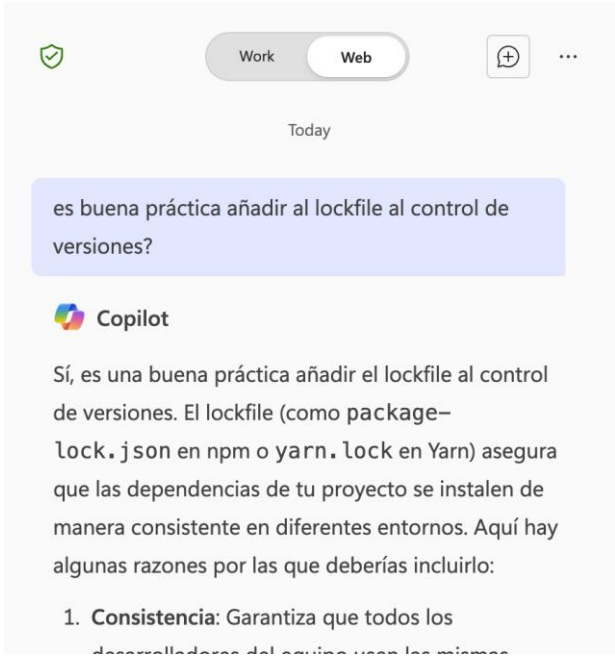

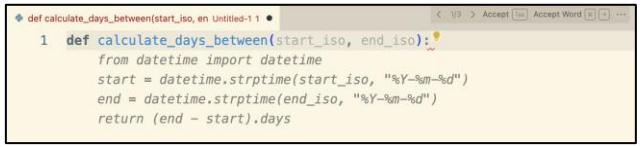

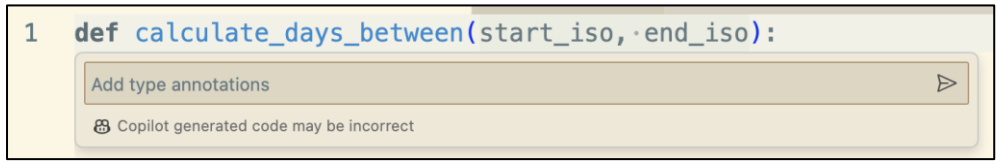

ChatGPT, GitHub Copilot, Bing Copilot y muchos otros productos **funcionan** con LLM.

LLM: Modelos de Lenguaje Grande

Un LLM es un modelo de machine learning tan grande que logra comprender y generar lenguaje de uso cotidiana

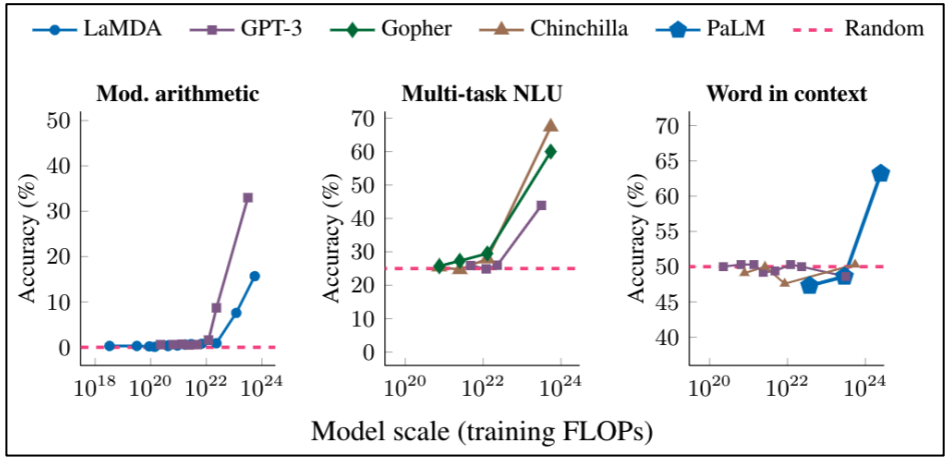

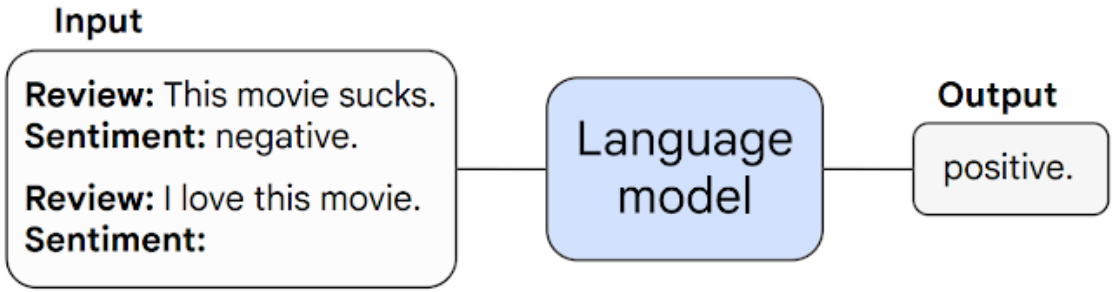

📖 Characterizing Emergent Phenomena in LLMs

Así funcionan los modelos lingüísticos

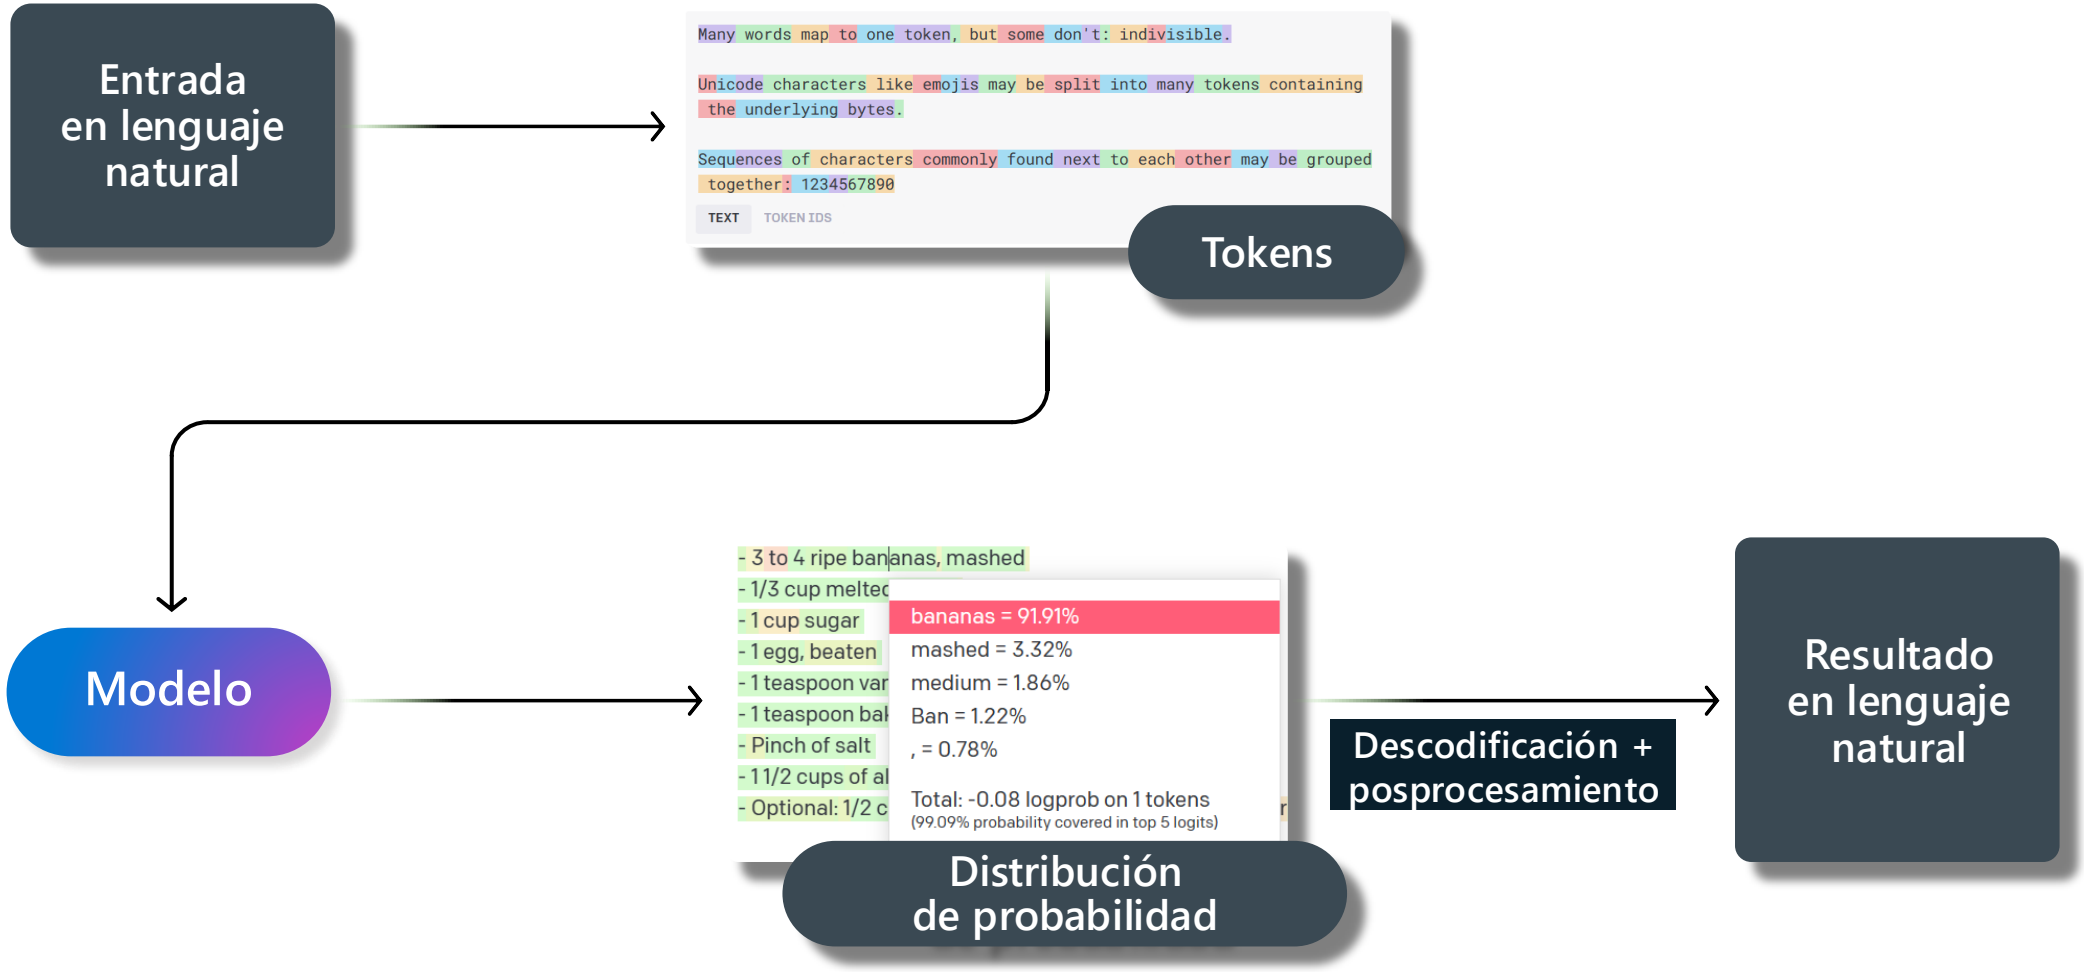

Preprocesamiento de la entrada: Tokenizaton

Input: “Hablaremos de llms”

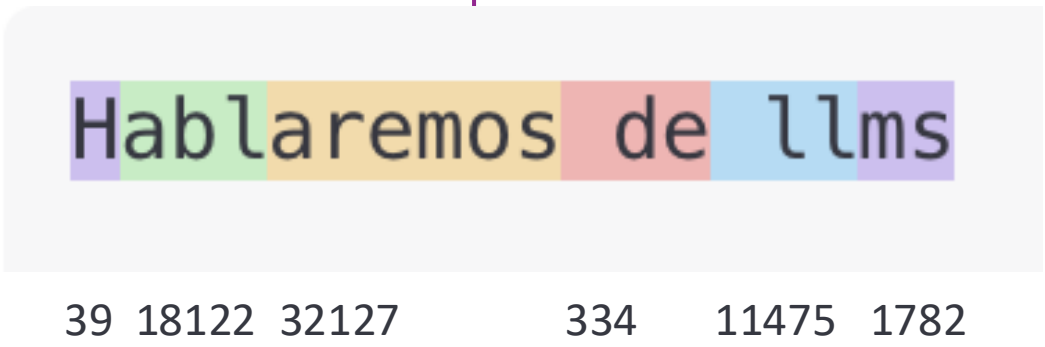

platform.openai.com/tokenizer

Entradas y salidas del modelo

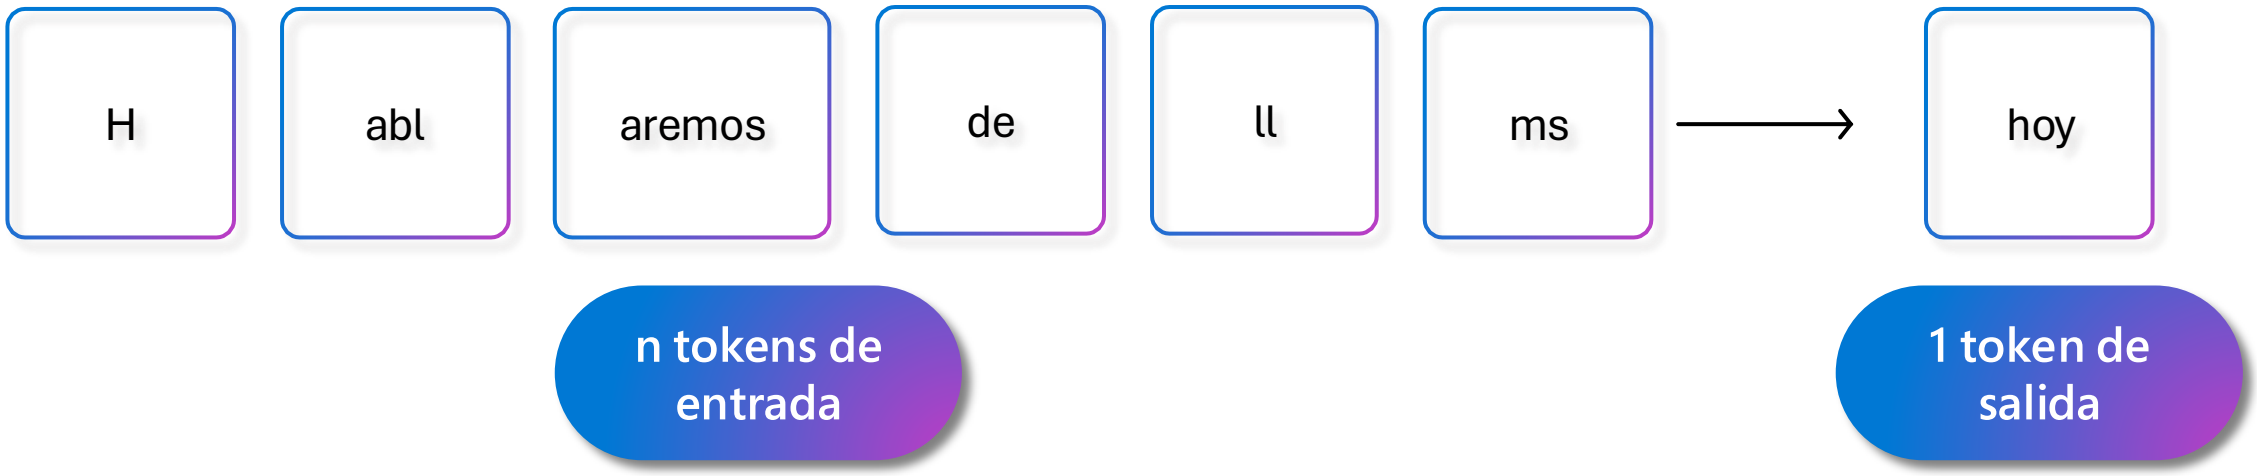

El contexto se expande

Hablaremos de los llms hoy

Hablaremos de los llms hoy en

Hablaremos de los llms hoy en la

Hablaremos de los llms hoy en la clase

Hablaremos de los llms hoy en la clase de

Hablaremos de los llms hoy en la clase de programación

Hablaremos de los llms hoy en la clase de programación .

Hablaremos de los llms hoy en la clase de programación.

Selección de token

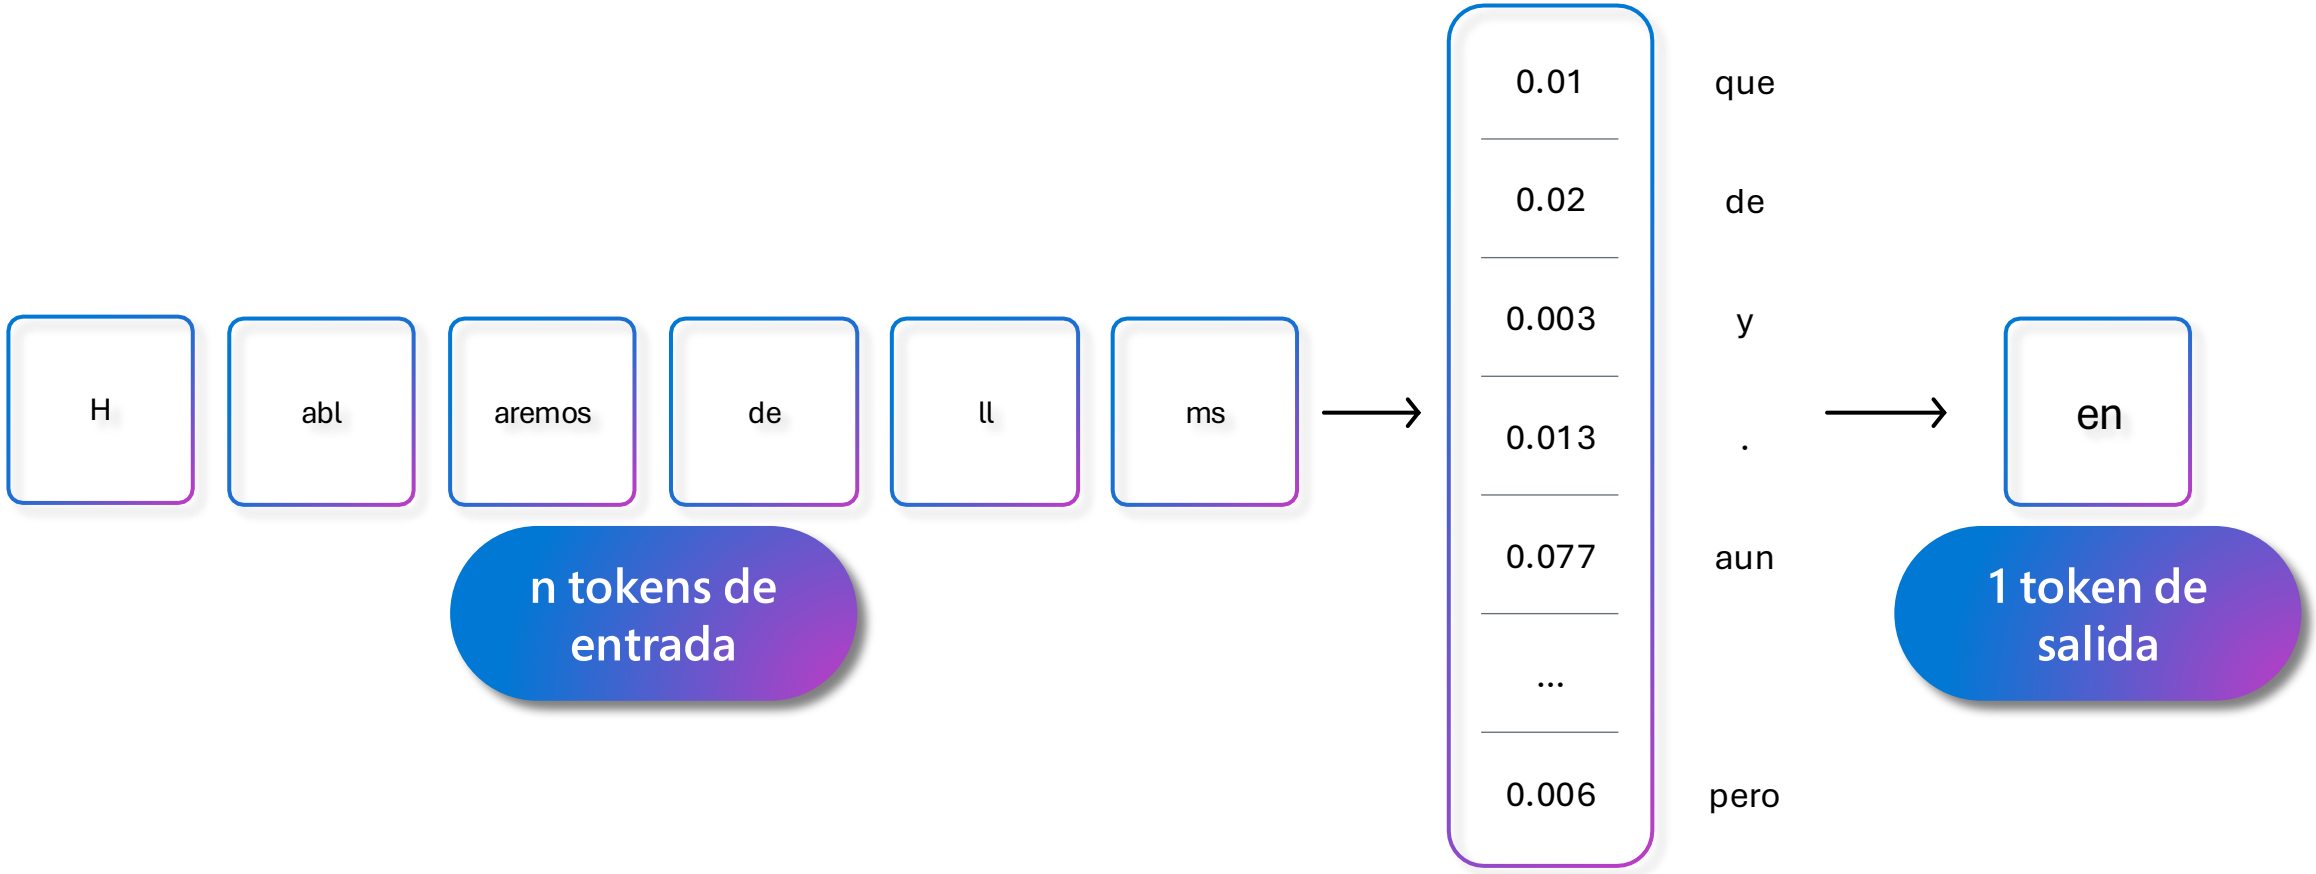

The Transformer Explainer

Simplemente, los LLMs predicen el siguiente token

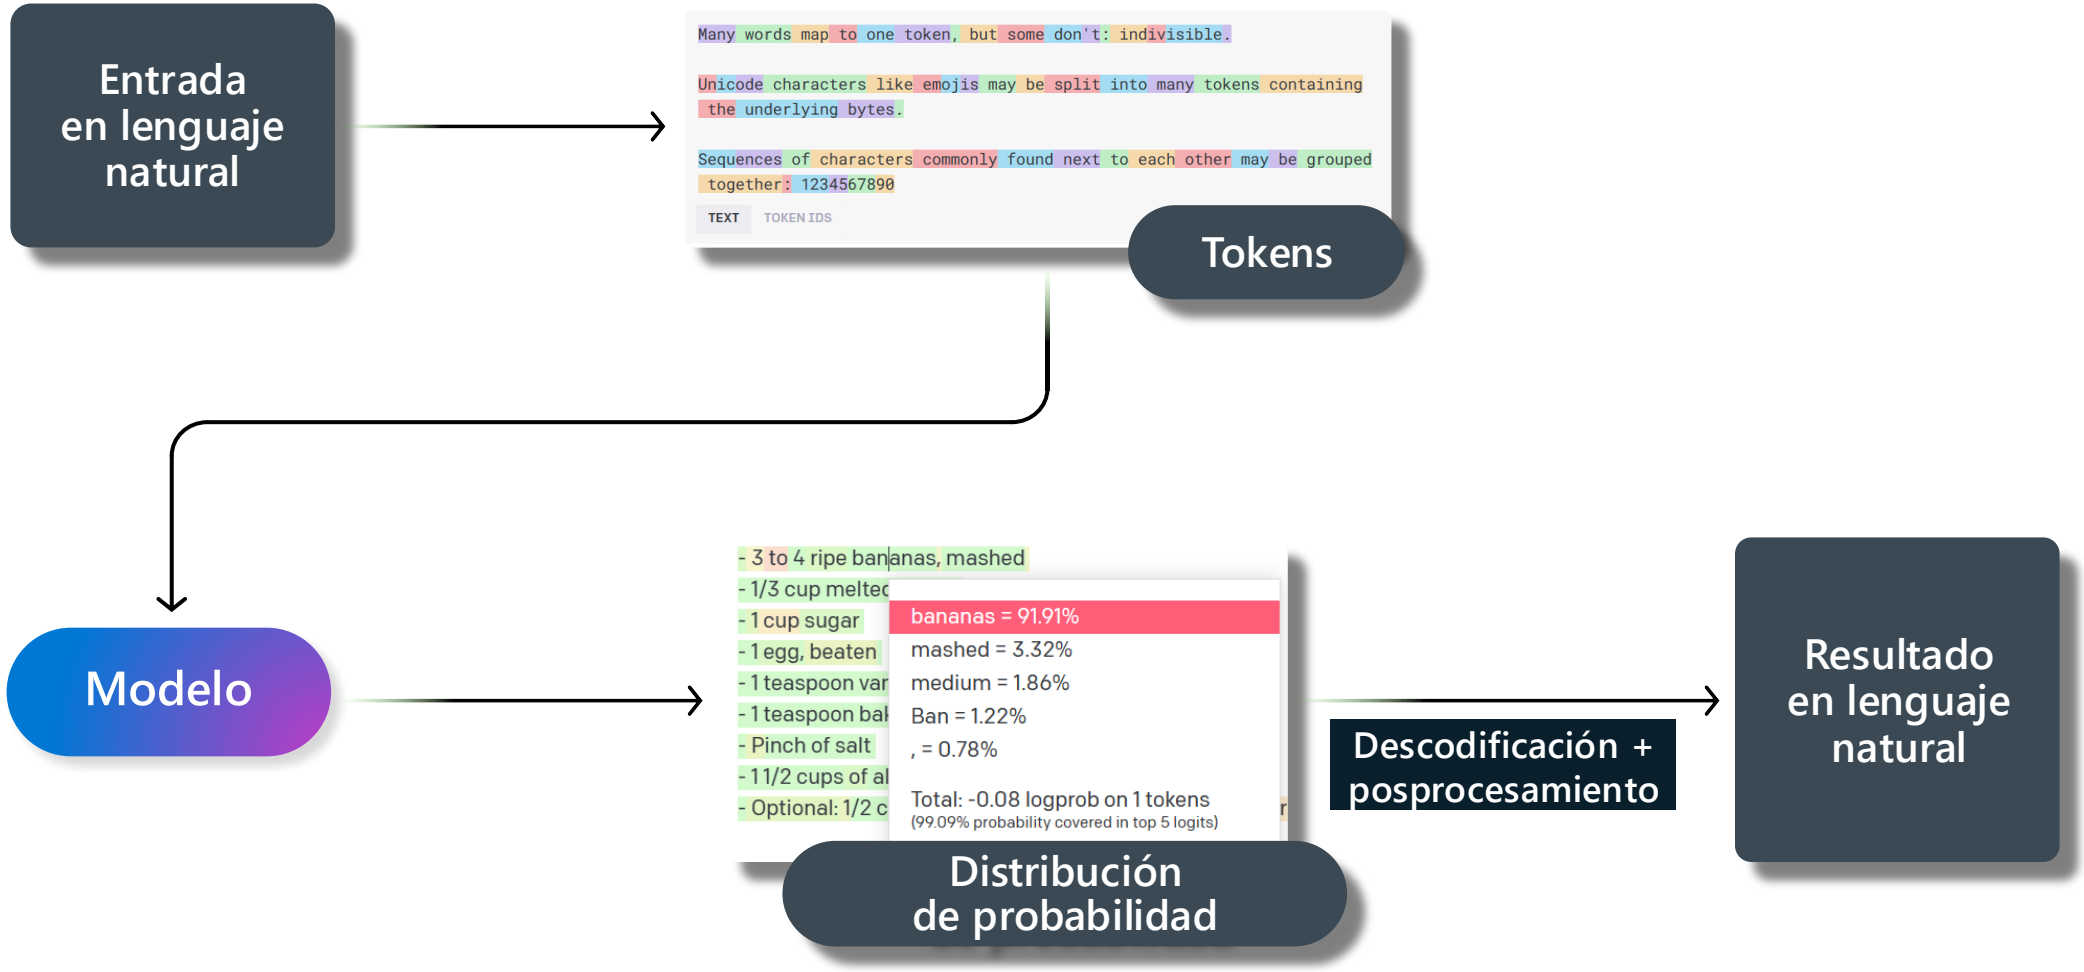

Opciones de modelos

Modelos gestionados

Los LLMs gestionados se pueden acceder a través de una API, desde una empresa que administra el modelo y la infraestructura para usted.

Host	Models
OpenAI.com	GPT-3.5 GPT-4 GPT-4o
Azure AI	OpenAI GPT models, Meta models, Cohere, Mistral, DeepSeek,...
GitHub Models (GRATIS)	Azure AI models
Google	Gemini 1, 1.5
Anthropic	Claude 3 family

Demo: GitHub Models

Cualquier usuario de GitHub puede usar los modelos y los playgrounds:

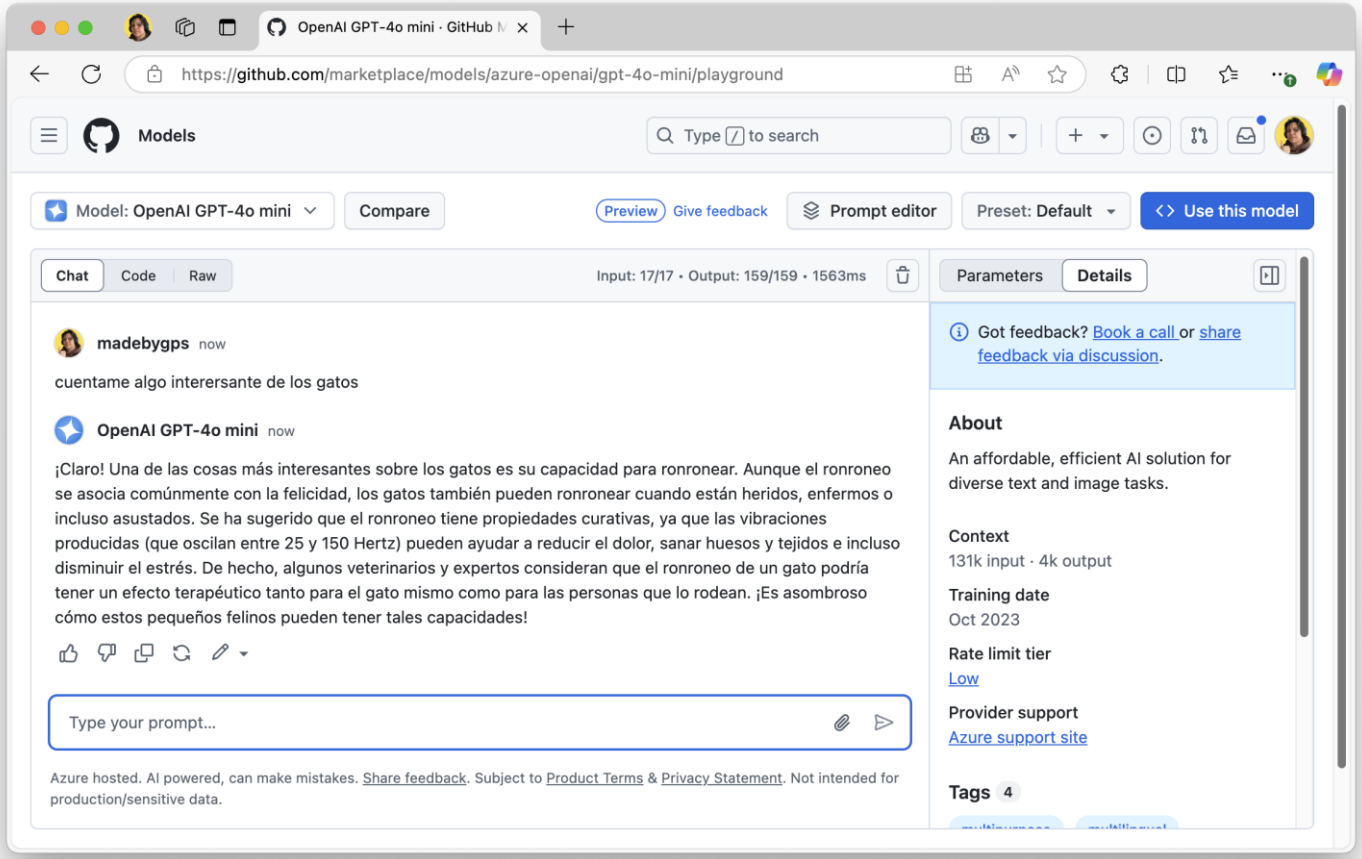

http://github.com/marketplace/models

Modelos locales

Los modelos locales tienen open weights y pueden funcionar en máquinas personales.

Los SLM = «Small Language Models» son modelos más pequeños, < 100 B parámetros.

Local model runners:

- Ollama
- Llamafile
- LM Studio

SLMs populares:

- Llama 3 series
- Phi4 series
- DeepSeek-R1
- Mistral
- Llava
- Gemma

Demo: Ollama

Ollama es una herramienta para ejecutar LLM locales en tu computadora.

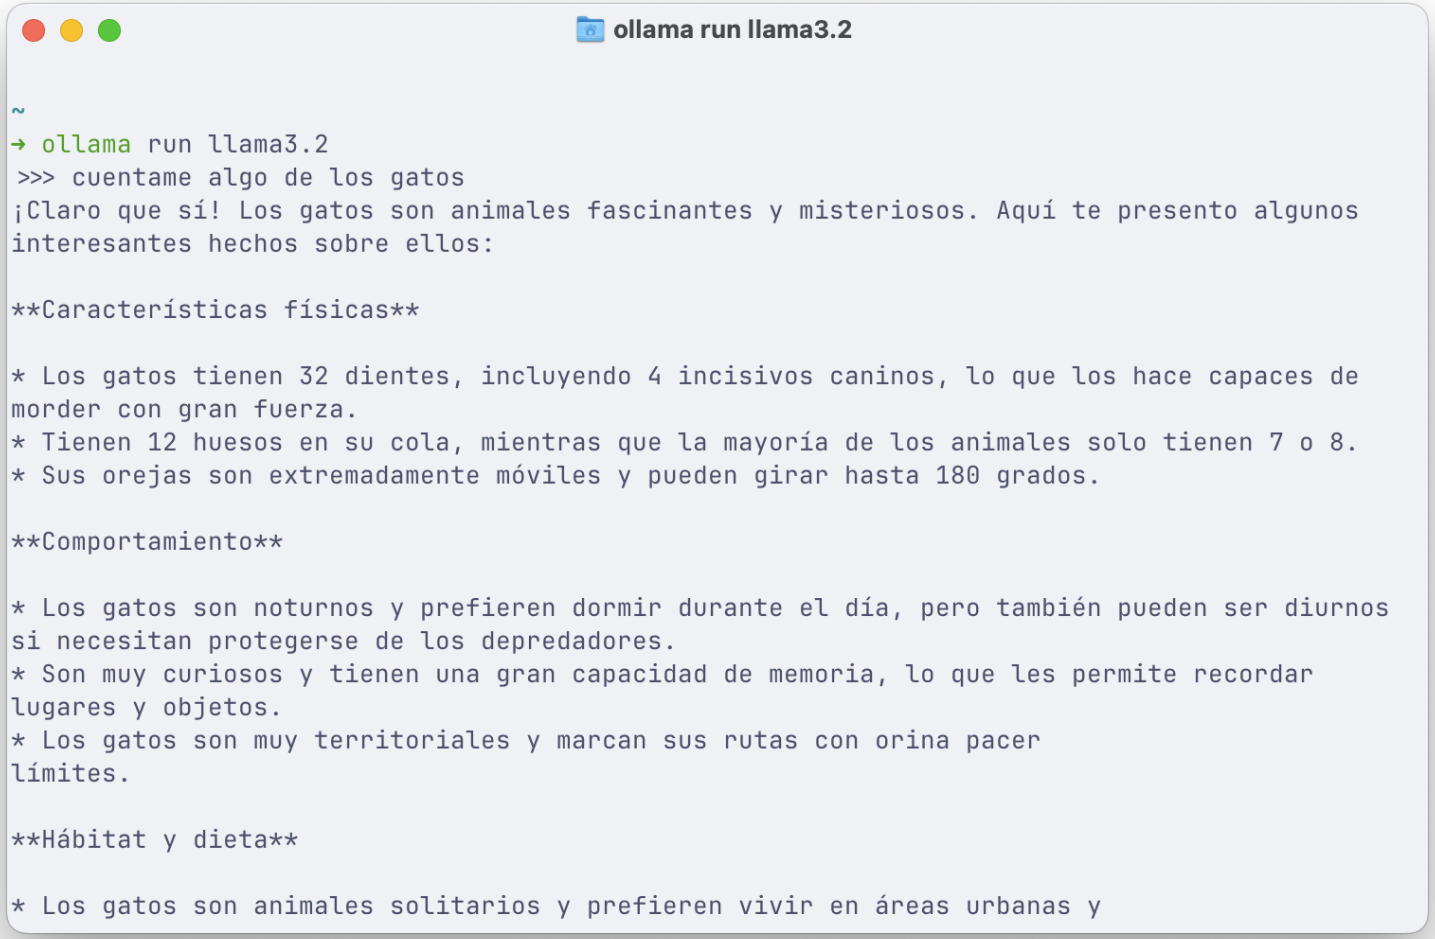

Usando LLMs desde Python

Librerías de Python para modelos de Azure AI

Estas librerías soportan directamente modelos gestionados por Azure/GitHub:

Librería	**Modelos compatibles**
openai	OpenAI.com models, Azure OpenAI models, OpenAI-compatible models
azure-ai-inference	Azure OpenAI, GitHub Models, Azure AI models
azure-ai-agents	Azure AI Agents service models

Más adelante hablaremos de librerías wrappers/orquestadores como Langchain.

Librería OpenAI

La librería Python oficial de openai está disponible en PyPI:

```
pip install openai
```

Incluye soporte para **chat completions**, **embeddings**, y más.

`openai` librería es compatible con modelos gestionados en varios lugares:

- Openai.com account
- Azure OpenAI account
- GitHub models
- Local con OpenAI-compatible API (Ollama/llamafile)

OpenAI demos repo

Usaremos este repo hoy o demos:

https://github.com/pamelafox/python-openai-demos/spanish

Usa estos enlaces para abrirlo con el host de OpenAI que prefieras:

- aka.ms/python-openai-github (GRATIS)
- aka.ms/python-openai-openai
- aka.ms/python-openai-azure
- aka.ms/python-openai-ollama

Autenticación API para hosts OpenAI

Para openai.com OpenAI, configura tu API key:

```
client = openai.OpenAI(api_key=os.environ["OPENAI_KEY"])
```

Para Azure OpenAI (keyless auth), usa Azure default credentials:

```
token_provider = azure.identity.get_bearer_token_provider(
  DefaultAzureCredential(), "https://cognitiveservices.azure.com/.default"
)
client = openai.AzureOpenAI(
  api_version=os.environ["AZURE_OPENAI_VERSION"],
  azure_endpoint=os.environ["AZURE_OPENAI_ENDPOINT"],
  azure_ad_token_provider=token_provider,
)
```

https://learn.microsoft.com/azure/developer/ai/keyless-connections

Autenticación API para OpenAI-like APIs

Para Ollama, configura tu base URL a localhost y key a cualquier valor:

```
client = openai.OpenAI(
  base_url="http://localhost:11434/v1",
  api_key="nokeyneeded",
)
```

Para GitHub models, configura tu base URL a GitHub models host y configura key a PAT (personal access token):

```
client = openai.OpenAI(
  base_url="https://models.inference.ai.azure.com",
  api_key=os.environ["GITHUB_TOKEN"])
```

👉🏽 En GitHub Codespaces, GITHUB_TOKEN siempre almacenará tu PAT. Si estás ejecutando localmente, crea un nuevo PAT.

Llamada a Chat Completion API

```
response = client.chat.completions.create(
  model="gpt-4o",
  temperature=0.7,
  max_tokens=30,
  n=1,
  messages=[
   {"role": "system", "content": "Eres un asistente útil que hace
      muchas referencias a gatos y usa emojis."},
   {"role": "user", "content": "Escribe un haiku sobre un gato
      hambriento que quiere atún"}
])

print(response.choices[0].message.content)
```

Ejemplo completo: chat.py

Transmite la respuesta

```
completion = client.chat.completions.create(
  model=MODEL_NAME,
  stream=True,
  messages=[
   {"role": "system", "content": "Eres un asistente útil que hace
       muchas referencias a gatos y usa emojis."},
   {"role": "user", "content": "Escribe un haiku sobre un gato
       hambriento que quiere atún"}
])

for event in completion:
  print(event.choices[0].delta.content, end="", flush=True)
```

Ejemplo completo: chat_stream.py

LLMs: Pros y Cons

Pros:

- Creativo 😊
- Genial con los patrones
- Bueno con sintaxis (natural y de programación)

Cons:

- Creativo 😖
- Inventa cosas (sin saberlo)
- Ventana de contexto limitada (4K-128K)
- Más tokens = más $, más tiempo

Como mejorar output del LLM

Maneras de mejorar LLM output

- **Prompt engineering**: Solicitar un tono y un formato específico
- **Few-shot examples**: Demostrar el formato de salida deseado
- **Llamadas encadenadas**: Haz que el LLM reflexione, reduzca la velocidad, lo descomponga
  - 😊 **cubriremos hoy**
- **Recuperación-Aumentada Generación (RAG)**: Proveer contexto al LLM just-in-time
  - 🔍 **cubriremos 3/18**
- **Llamada a funciones y salidas estructuradas**
  - 🛠️ **cubriremos 3/25**
- **Fine tuning**: Enseñar a LLM nueva información alterando permanentemente los weights

Prompt engineering

El primer mensaje enviado al modelo se llama «system message» o «system prompt». Utilízalo para establecer orientación general y reglas de formato.

```
response = client.chat.completions.create(
  model=MODEL_NAME,
  temperature=0.7,
  messages=[
    {"role": "system", "content": "Responde como Yoda"},
    {"role": "user", "content": "¿Que es un LLM?"},
  ]
)
```

Ejemplo completo: prompt_engineering.py

Few-shot ejemplos

Otra forma de guiar a un modelo de lenguaje es proporcionar "few shots", es decir, una secuencia de ejemplos de preguntas y respuestas que demuestran cómo debería responder.

```
response = client.chat.completions.create(model=MODEL_NAME,
  messages=[
    {"role": "system", "content": "Eres un tutor que da pistas, no respuestas."},
    {"role": "user", "content": "¿Cual es la capital de Francia?"},
    {"role": "assistant", "content": "¿Puedes pensar en la ciudad conocida por la Torre Eiffel?"},
    {"role": "user", "content": "¿Cuál es la raíz cuadrada de 144?"},
    {"role": "assistant", "content": "¿Qué número multiplicado por sí mismo es igual a 144?"},
    {"role": "user", "content": "¿Cuál es el número atómico del oxígeno?"},
    {"role": "assistant", "content": "¿Cuántos protones tiene un átomo de oxígeno?"},
    {"role": "user", "content": "¿Cuál es el planeta más grande del sistema solar?"},
])
```

Ejemplo completo: few_shot_examples.py

Chained calls

```
response = client.chat.completions.create(model=MODEL_NAME,
  messages=[{"role": "user",
    "content": "Explica cómo funcionan los LLM en un solo párrafo."}])
explanation = response.choices[0].message.content

response = client.chat.completions.create(model=MODEL_NAME,
  messages=[{"role": "user",
    "content": f"Eres un editor. Revisa la siguiente explicación y proporciona
comentarios detallados sobre claridad, coherencia y cautivación. \n Explicación: \n
{explanation}"}])
feedback = response.choices[0].message.content

response = client.chat.completions.create(model=MODEL_NAME,
  messages=[{"role": "user",
    "content": f"Revisa el articulo usando los comentarios siguientes pero mantenlo a
un solo párrafo. \n Explicación:\n {explanation} \n\n Comentarios:\n{feedback}"}])
final_article = response.choices[0].message.content
```

Ejemplo completo: chained_calls.py

Librerías populares LLM

LLM librerías

Muchas librerías Python ofrecen una capa de abstracción para trabajar con LLMs:

- Langchain: Orquestación
- Llamaindex: Orquestación para RAG y Agentes
- PydanticAI: Orquestación para RAG y Agentes
- Semantic Kernel: Orquestación
- Autogen: Orquestación para flujos de agentes
- Litellm: Wrapper para varios hosts
- ...¡y muchos más!

Langchain

Conectando a GitHub models a través de Langchain:

```
from langchain_openai import ChatOpenAI

llm = ChatOpenAI(
  model_name=os.environ["GITHUB_MODEL"],
  openai_api_base="https://models.inference.ai.azure.com",
  openai_api_key=os.environ["GITHUB_TOKEN"]
)
prompt = ChatPromptTemplate.from_messages(
  [("system", "Eres un asistente útil que hace muchas referencias a
gatos."),
   ("user", "{input}")]
)
chain = prompt | llm
response = chain.invoke(
  {"input": "escribe un haiku sobre un gato hambriento que quiere atún
"})
```

Ejemplo completo: chat_langchain.py

Llamaindex

Conectando a GitHub models a través de Llamaindex:

```
from llama_index.llms.openai_like import OpenAILike

llm = OpenAILike(
  model=os.environ["GITHUB_MODEL"],
  api_base="https://models.inference.ai.azure.com",
  api_key=os.environ["GITHUB_TOKEN"],
  is_chat_model=True,
)
chat_msgs = [
  ChatMessage(role=MessageRole.SYSTEM,
    content="Eres un asistente útil que hace muchas referencias a gatos."),
  ChatMessage(role=MessageRole.USER,
    content="escribe un haiku sobre un gato hambriento que quiere atún"),
]
response = llm.chat(chat_msgs)
```

Ejemplo completo: chat_llamaindex.py

Pydantic AI

Conectando a GitHub models a través de Pydantic AI:

```
from pydantic_ai.models.openai import OpenAIModel

llm = OpenAIModel(
  model="gpt-4o",
  base_url="https://models.inference.ai.azure.com",
  api_key=os.environ["GITHUB_TOKEN"]
)

agent = Agent(model, system_prompt="Eres un asistente útil que hace
muchas referencias a gatos.

result = agent.run_sync("escribe un haiku sobre un gato hambriento que
quiere atún")
```

Ejemplo completo: chat_pydanticai.py

Cómo elegir una librería LLM

Considera:

- ¿Es compatible con todos los LLM/host que necesitas?
- ¿Tiene las funciones que necesitas (streaming, herramientas, etc.)?
- ¿Es fácil de usar y debuggear?
- ¿Está activamente mantenido?
- ¿Merecen la pena las ventajas?

Desarrollando aplicaciones impulsadas por LLMs

Chat + vision app

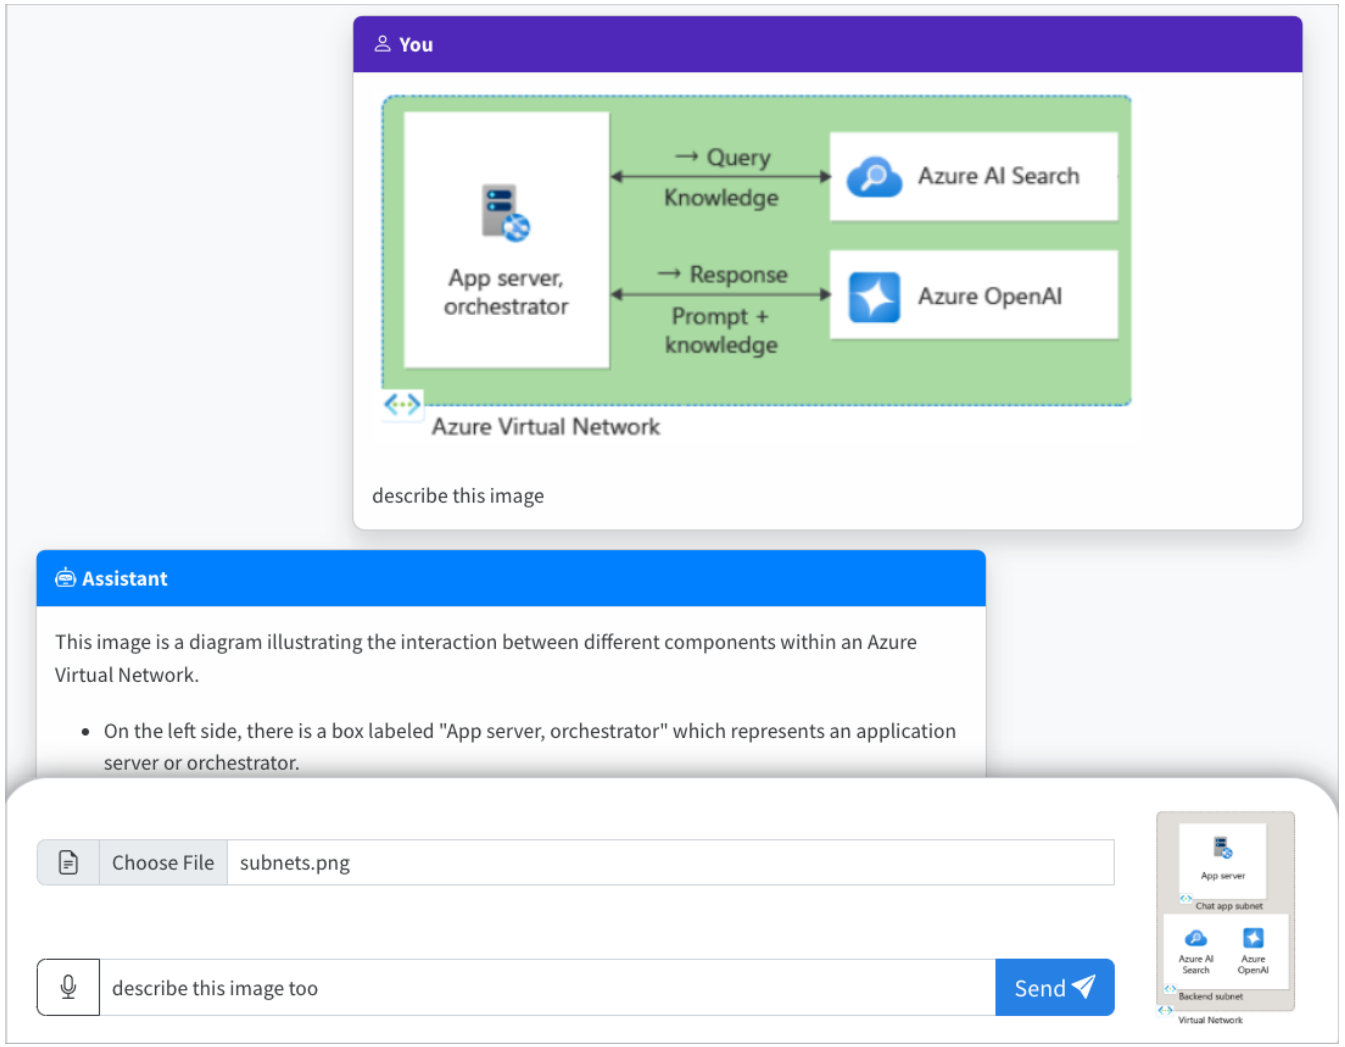

Supported model hosts:

- Azure OpenAI
- GitHub Models

Features:

- Streaming
- Speech I/O
- Image upload*

Code:
aka.ms/chat-vision-app

Profundizaremos en los modelos de visión en la sesión del 3/19.

App architectura

Frontend

(HTML, JavaScript)

Python backend

(Quart, Uvicorn)

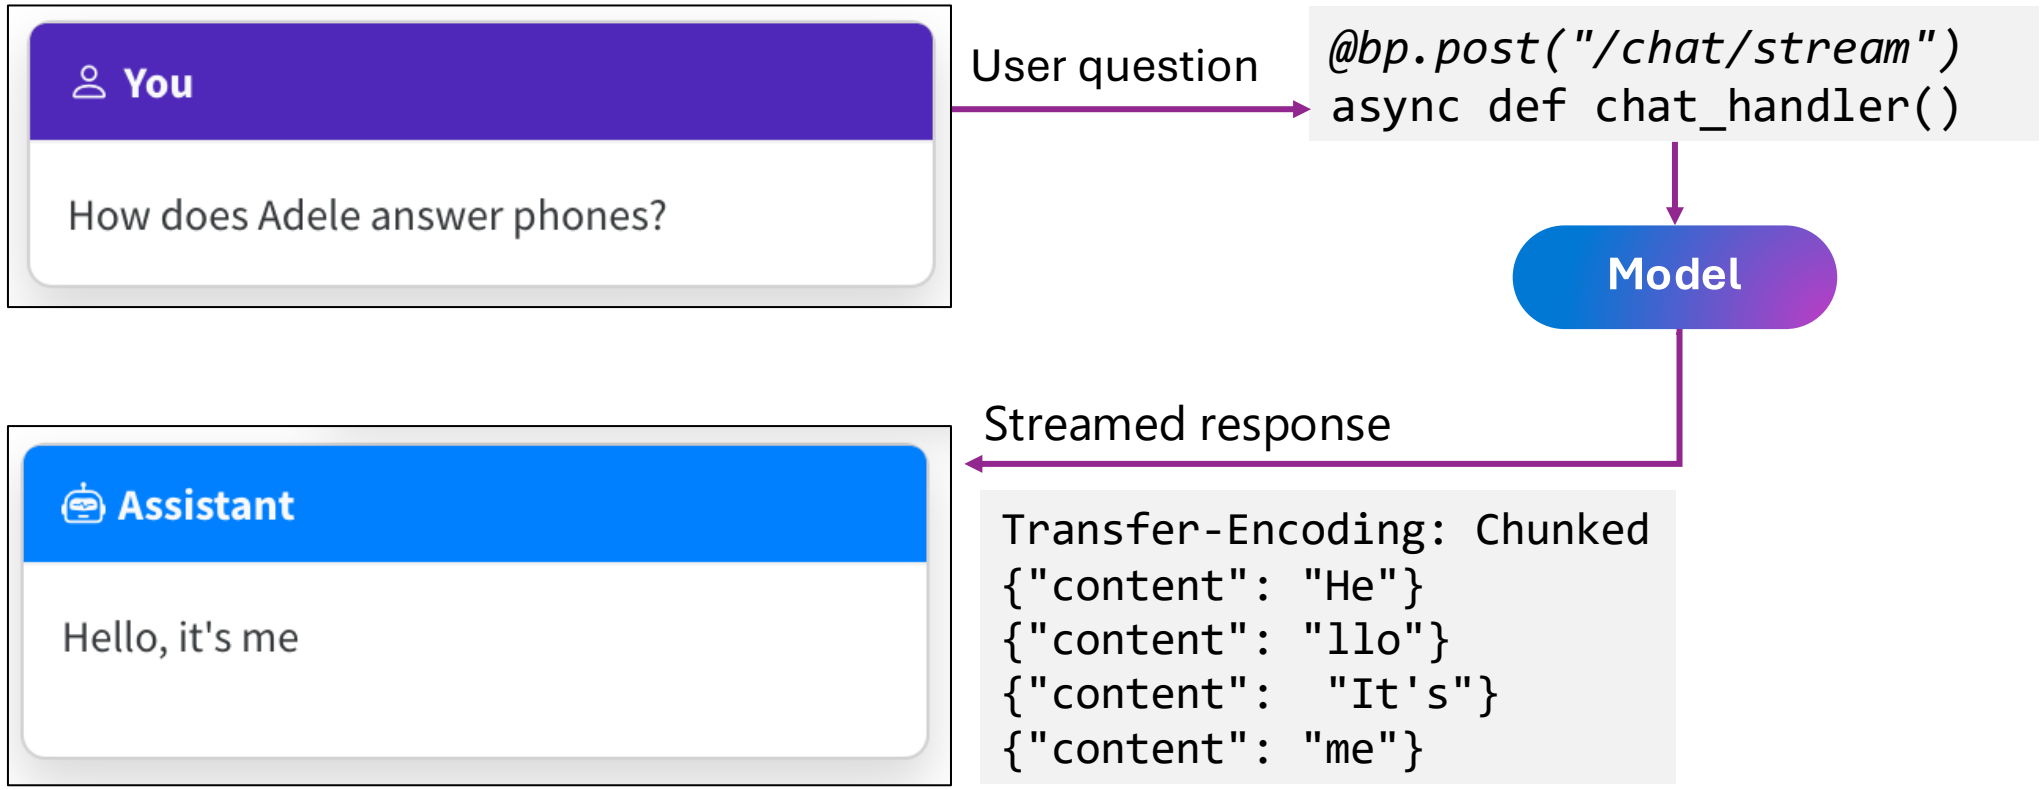

Streaming respuestas en Quart

```
@bp.post("/chat/stream")
async def chat_handler():
  request_json = await request.get_json()

        @stream_with_context
        async def response_stream():

        chat_coroutine = bp.openai_client.chat.completions.create(
          model=os.environ["OPENAI_MODEL"],
          messages=request_json["messages"],
          stream=True,
        )
        async for event in await chat_coroutine:
          event_dict = event.model_dump()
          yield json.dumps(event_dict["choices"][0], ensure_ascii=False) + "\n"

return Response(response_stream())
```

blog.pamelafox.org/2023/09/best-practices-for-openai-chat-apps_16.html

P: ¿Por qué el backend utiliza Quart?

Muchos desarrolladores empiezan con Flask, uno de los framework web más popular.

Un framework **síncrono** (como Flask) solo puede gestionar 1 petición por worker:

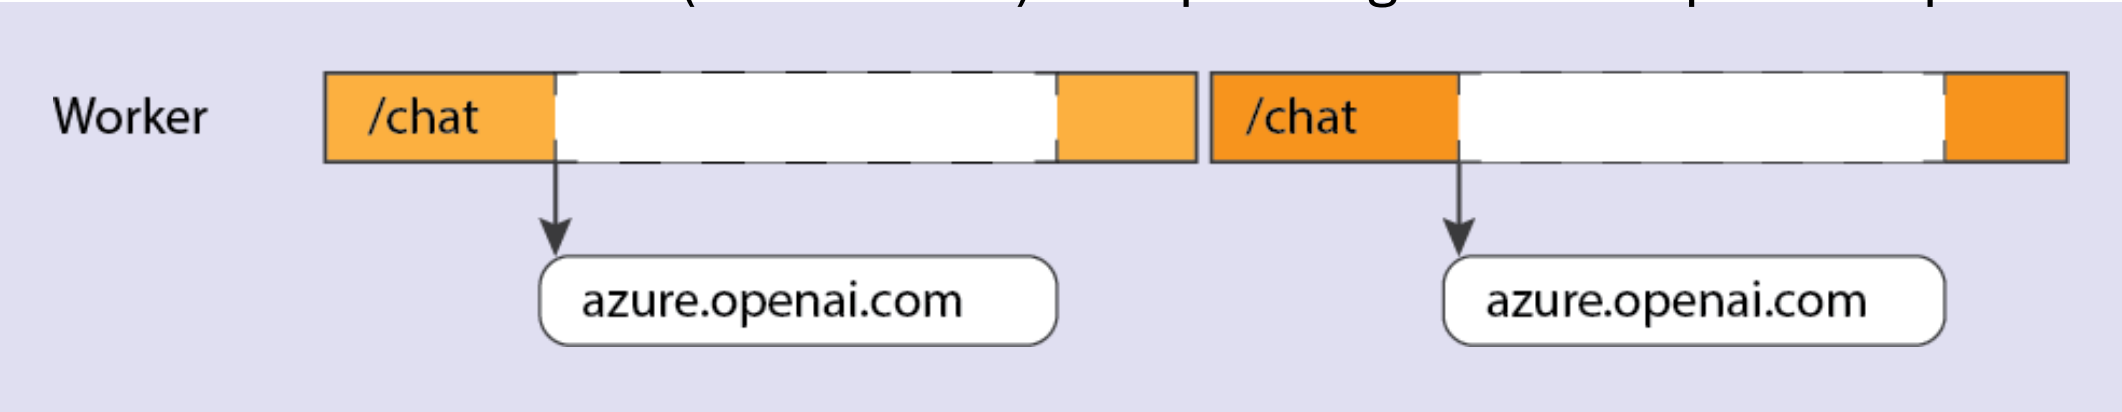

https://blog.pamelafox.org/2023/09/best-practices-for-openai-chat-apps.html

R: ¿Por qué el backend utiliza Quart?

Quart es la versión **asíncrona** de Flask.

Un framework **asíncrono** puede gestionar nuevas peticiones mientras espera la I/O:

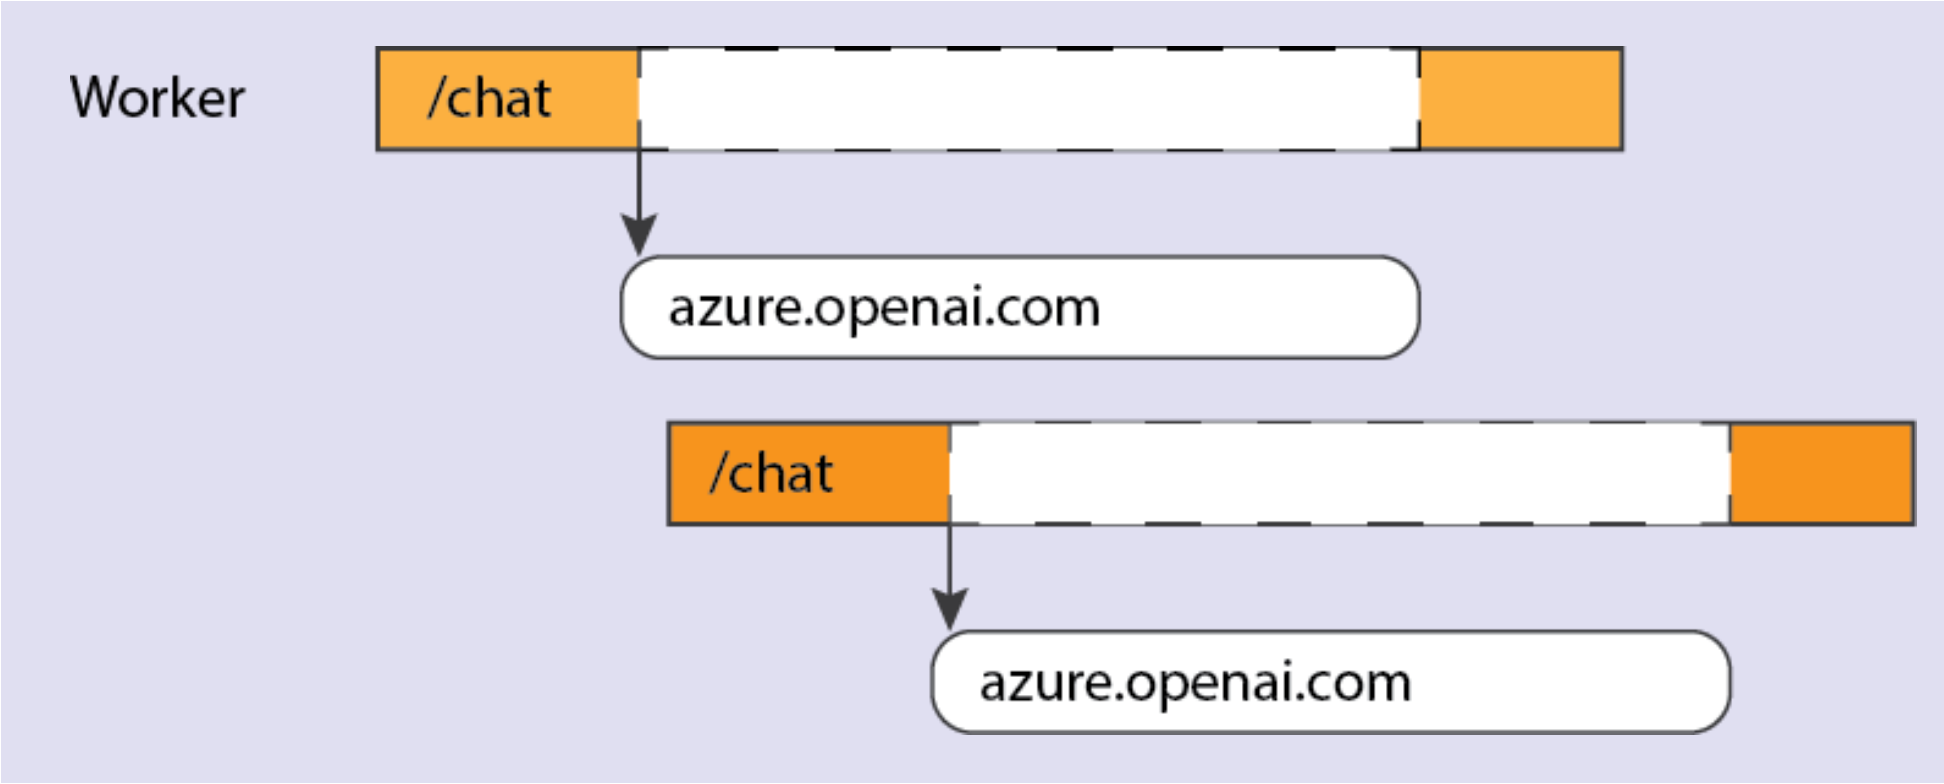

Async frameworks para Python

Hay varias opciones populares:

Framework	Ejemplo apps para Azure AI
Quart	aka.ms/azai/chat aka.ms/chat-vision-app aka.ms/ragchat
FastAPI	aka.ms/azai/fastapi aka.ms/rag-postgres
Aiohttp	aka.ms/voicerag/repo
Django con async	

https://blog.pamelafox.org/2024/07/should-you-use-quart-or-fastapi-for-ai.html

Próximos pasos

¡Únete a los próximos streams! →

Ven a las horas de oficina los Lunes en Discord:
aka.ms/pythonia/ho

Obtén más recursos de Python AI
aka.ms/thesource/Python_AI

🧠 3/11: LLMs

↖ 3/13: Vector embeddings

🔍 3/18: RAG

🖼️ 3/19: Models de Vision

🛠️ 3/25: Salidas estructuradas

🛡️ 3/27: Calidad y Seguridad

Regístrate @ aka.ms/PythonIA/series

Gracias